

假设训练集:  $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$ ,

通过联合分布建模数据:

$$p(x^{(i)}, z^{(i)}) = p(x^{(i)} | z^{(i)}) \cdot p(z^{(i)}),$$

其中,  $z^{(i)} \sim$  服从多项分布, 以  $\phi$  为参数,

且  $\sum_{j=1}^k \phi_j = 1$ ,  $\phi_j > 0$ , 表示第  $j$  类出现的概率;

$$p(z^{(i)} = j) = \phi_j.$$

混合高斯模型 GMM 可以写为:

$$\ell(\phi, \mu, \Sigma) = \sum_{i=1}^m \log q(x^{(i)}; \phi, \mu, \Sigma)$$

$$= \sum_{i=1}^m \log \cdot \sum_{j=1}^k p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) \cdot p(z^{(i)} = j; \phi).$$

这里,  $x^{(i)} | z^{(i)} = j \sim \mathcal{N}(\mu_j, \Sigma_j)$ , 表示  $x^{(i)}$  服从第

$j$  个高斯分布的概率,  $z^{(i)}$  被称作隐变量

目标：求解  $\phi, \mu, \Sigma$  参数，使其满足给定数据  $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$  下的最大似然。

直接求解（令导数为0），不可行。

由于  $z^{(i)}$  表示每个  $x^{(i)}$  来自于  $K$  个高斯中的哪个，  
假设已知  $z^{(i)}$ ，则问题其实很简单：

$$\ell(\phi, \mu, \Sigma) = \sum_{i=1}^m \log p(x^{(i)} | z^{(i)}; \mu, \Sigma) + \log p(z^{(i)}; \phi)$$

最大似然计算为：

$$\phi_j = \frac{1}{m} \sum_{i=1}^m \{z^{(i)} = j\}$$

$$\mu_j = \frac{\sum_{i=1}^m \{z^{(i)} = j\} \cdot x^{(i)}}{\sum_{i=1}^m \{z^{(i)} = j\}}$$

$$\Sigma_j = \frac{\sum_{i=1}^m \{z^{(i)} = j\} (x^{(i)} - \mu_j)(x^{(i)} - \mu_j)^T}{\sum_{i=1}^m \{z^{(i)} = j\}}$$

则EM算法为：(迭代以下两步直到收敛，

E步：预测  $z^{(i)}$  的值

对每个  $i, j$ ，令：

$$w_j^{(i)} = p(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma),$$

其中：

$$p(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma) = \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) \cdot p(z^{(i)} = j; \phi)}{\sum_{l=1}^K p(x^{(i)} | z^{(i)} = l; \mu, \Sigma) \cdot p(z^{(i)} = l; \phi)}$$

$$= \frac{\mathcal{N}(x^{(i)}; \mu_j, \Sigma_j) \cdot \phi_j}{\sum_{l=1}^K \mathcal{N}(x^{(i)}; \mu_l, \Sigma_l) \cdot \phi_l}$$

M步：基于预测更新模型参数：

$$\phi_j = \frac{1}{m} \sum_{i=1}^m w_j^{(i)}$$

$$\mu_j = \frac{\sum_{i=1}^m w_j^{(i)} x^{(i)}}{\sum_{i=1}^m w_j^{(i)}}$$

$$\Sigma_j = \frac{\sum_{i=1}^m w_j^{(i)} (x^{(i)} - \mu_j)(x^{(i)} - \mu_j)^T}{\sum_{i=1}^m w_j^{(i)}}$$

EM算法和k-mean很像，区别为：

① k-mean 为“硬聚类”  $c(i)$

② Gmm 为“软聚类”  $w_j^{(i)}$

## 关于 EM 算法 - 一个更 general 的解释.

EM 算法可用于任何包含隐变量的参数估计。

引子: Jensen 不等式:

设  $f$  为凸函数 (即  $f''(x) > 0, \forall x \in \mathbb{R}$ ).

当  $x$  为向量时, 条件变为海森矩阵  $H$  为半正定:  $H \geq 0$ .

Jensen 不等式表述为:

$f$  为凸函数,  $x$  为随机变量, 则:

$$E[f(x)] \geq f(E[x])$$

当且仅当  $x = E[x]$  以概率 1 成立, 即  $x$  为常数.

EM 算法:

给定训练集  $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$ , 据此数据拟合

概率模型  $p(x, z)$ , 定义似然:

$$l(\theta) = \sum_{i=1}^m \log p(x; \theta)$$

$$= \sum_{i=1}^m \log \sum_{\mathbf{z}} p(\mathbf{x}^{(i)}, \mathbf{z}; \theta)$$

其中,  $\mathbf{z}^{(i)}$  为隐变量, 当  $\mathbf{z}^{(i)}$  已知时, 通常上面的方程很好解。

直接优化似然  $l(\theta)$  很困难, 于是通过迭代:

① 构造  $l$  上的下界

② 优化 (最大化, 下界)

对每个  $i$ , 定义  $Q_i$  为  $\mathbf{z}$  上的分布, 即:

$$\sum_{\mathbf{z}} Q_i(\mathbf{z}) = 1, \quad Q_i(\mathbf{z}) \geq 0$$

考虑下式:

$$\begin{aligned} \sum_{i=1}^m \log p(\mathbf{x}^{(i)}; \theta) &= \sum_{i=1}^m \log \sum_{\mathbf{z}^{(i)}} p(\mathbf{x}^{(i)}, \mathbf{z}^{(i)}; \theta) \\ &= \sum_{i=1}^m \log \sum_{\mathbf{z}^{(i)}} Q_i(\mathbf{z}^{(i)}) \frac{p(\mathbf{x}^{(i)}, \mathbf{z}^{(i)}; \theta)}{Q_i(\mathbf{z}^{(i)})} \\ &\geq \sum_{i=1}^m \sum_{\mathbf{z}^{(i)}} Q_i(\mathbf{z}^{(i)}) \log \frac{p(\mathbf{x}^{(i)}, \mathbf{z}^{(i)}; \theta)}{Q_i(\mathbf{z}^{(i)})} \end{aligned}$$

最后一步用了 Jensen 不等式, 且  $f(x) = \log(x)$ ,

随机变量  $x$  为  $\log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}$  (关于  $z^{(i)}$  的),

满足  $Q_i(z^{(i)})$  的分布, 则有:

$$f(E_{z^{(i)} \sim Q_i} [\log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}]) \geq E_{z^{(i)} \sim Q_i} [f(\log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})})]$$

注: 由于  $f(x) = \log(x)$  为 concave, 所以符号反转了。

则对于每个分布, 上式都给出了  $\log(\cdot)$  的一个下界。

并且这里的  $Q_i$  还是未知的, 不过如果我们已经估计了当前的参数  $\theta$ , 则可以在这个  $\theta$  下优化下界, 即使上面的不等式取等号, 即:

$$\frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} = c$$

而又因为  $\sum_z Q_i(z^{(i)}) = 1$ , 则:

$$Q_i(z^{(i)}) = \frac{p(x^{(i)}, z^{(i)}; \theta)}{\sum_z p(x^{(i)}, z^{(i)}; \theta)} = \frac{p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}; \theta)}$$

$$= p(z^{(i)} | x^{(i)}; \theta)$$

可以看到, 这还是一个关于  $z^{(i)}$  的分布。

总结一下就是:

E步:  $Q_i(z^{(i)}) = p(z^{(i)} | x^{(i)}; \theta)$

M步:  $\theta = \arg \max_{\theta} \sum_{i=1}^m \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}$